




Institute for Data Science & Artificial Intelligence

PCA, LDA & SVMs

Temel Bileşen Analiz (Principal Component Analysis (PCA))



- ❑ Öznitelikler makine öğrenmesi modellerinin girdi olarak kullandıkları niceliklerdir.
 - Öznitelikler, eğitim verileri kullanılarak direk oluşturulur veya değişik mekanizmalarla türetilirler.
 - Öznitelikler eğitim verilerinin “**özlü**” temsilleridir.

Boyut indirgeme (dimensionality reduction) nedir ve neden buna ihtiyaç duyarız?

Tanım (Boyut indirgeme)

Boyut indirgeme (dimensionality reduction), yüksek boyutlu bir veri kümesini, temel yapısını ve ayırt edici bilgisini koruyacak şekilde daha *düşük boyutlu* bir özellik uzayında temsil etme sürecidir.

Neden boyut indirmeye ihtiyaç duyarız?

- Zaman karmaşıklığını (time complexity'i) azaltır: daha az hesaplama zamanı gerektirir.
- Uzay karmaşıklığını (space complexity'i) azaltır: daha az parametre gerektirir.
- Özniteliğin gözlemlenmesi ya da hesaplanması için katlanılan maliyetten tasarruf sağlar.
- Daha basit modeller, küçük boyutlu veri kümeleri üzerinde daha sağlam (robust) sonuçlar verir.
- Daha kolay yorumlanır; daha sade biçimde açıklanabilir.
- Veri, 2 veya 3 boyutta gösterildiğinde yapının, grupların, aykırı değerlerin vb. görselleştirilmesini sağlar.

Doğrusal boyut indirgemedede doğrusal bir dönüşüm (linear mapping) kullanılır:

$$\mathbf{z} = f(\mathbf{x}) = A\mathbf{x}$$

burada $A \in \mathbb{R}^{k \times d}$ dönüşüm (transformasyon) matris parametrelerini içerir.

Bu derste, doğrusal boyut indirgeme için aşağıdaki iki yöntemi ele alacağız:

- Temel Bileşen Analiz (Principal component analysis (PCA))
- Doğrusal Ayırt Edici Analiz (Linear discriminant analysis (LDA))



Temel Bileşen Analiz (PCA) (1)

Temel Bileşen Analiz (PCA), aşağıdaki ilkeye dayanır:

daha fazla bilgi $\Leftrightarrow$ daha büyük varyans

PCA'nın amacı, maksimum varyansı sağlayacak birbirine dik (orthogonal) izdüşüm yönlerini **ardışık** olarak belirlemektir.

$\mathbf{x}$ vektörünün $\mathbf{w}$ yönündeki izdüşümü : $\underbrace{\mathbf{x}}_{\text{vektör}} \xrightarrow{z = \mathbf{w}^T \mathbf{x}} \underbrace{z}_{\text{skaler}}$



$$\mathbf{x} \xrightarrow{z = \mathbf{w}^T \mathbf{x}} z \qquad \{\mathbf{x}^1, \mathbf{x}^2, \dots, \mathbf{x}^N\} \xrightarrow{z = \mathbf{w}^T \mathbf{x}} \{z^1, z^2, \dots, z^N\}$$

$$\begin{aligned} \sigma^2 &= \frac{1}{N} \sum_{i=1}^N (z^i - \bar{z})^2 \\ &= \mathbf{w}^T \underbrace{\left[\frac{1}{N} \sum_{i=1}^N (\mathbf{x}^i - \bar{\mathbf{x}})(\mathbf{x}^i - \bar{\mathbf{x}})^T \right]}_{\mathbf{S}: \text{ veri kovaryans matrisi} \\ &\quad \text{(sample covariance matrix)}} \mathbf{w} \\ &= \mathbf{w}^T \mathbf{S} \mathbf{w} \end{aligned}$$

Birinci temel bileşen aşağıdaki şekilde elde edilebilir:

$$\mathbf{w}_1^* = \underset{\mathbf{w}_1}{\operatorname{argmax}} \mathbf{w}_1^T \mathbf{S} \mathbf{w}_1$$

kısıt altında
(subject to)

$$\mathbf{w}_1^T \mathbf{w}_1 = 1$$

$$\mathbf{w}_1^* = \underset{\mathbf{w}_1}{\operatorname{argmax}} \mathbf{w}_1^T \mathbf{S} \mathbf{w}_1$$

kısıt altında
(subject to)
 $\mathbf{w}_1^T \mathbf{w}_1 = 1$

Bunu bir Lagrange optimizasyon problemi olarak yazabiliriz:

$$\mathbf{w}_1^* = \underset{\mathbf{w}_1}{\operatorname{argmax}} [\mathbf{w}_1^T \mathbf{S} \mathbf{w}_1 - \alpha (\mathbf{w}_1^T \mathbf{w}_1 - 1)]$$

$\mathbf{w}_1$ 'ye göre türev alıp sonucu 0'a eşitlediğimizde, şunu elde ederiz:

$$\mathbf{S} \mathbf{w}_1 = \alpha \mathbf{w}_1$$

Bu da, birinci temel bileşen $\mathbf{w}_1^*$ 'in $\mathbf{S}$ matrisinin bir özvektörü (eigenvector'ü) olduğu anlamına gelir.

İzdüşüm varyansı (projection variance) karşılık gelen özdeğere (eigenvalue'ye) eşittir:

$$\sigma^2 = \mathbf{w}_1^{*T} \mathbf{S} \mathbf{w}_1^* = \mathbf{w}_1^{*T} \alpha \mathbf{w}_1^* = \alpha \underbrace{\mathbf{w}_1^{*T} \mathbf{w}_1^*}_{=1} = \alpha$$

$$\begin{aligned} \mathbf{w}_1^* = \operatorname{argmax}_{\mathbf{w}_1} \mathbf{w}_1^T \mathbf{S} \mathbf{w}_1 \\ \text{kısıt altında} \quad \Leftrightarrow \quad \mathbf{S} \mathbf{w}_1 = \alpha \mathbf{w}_1 \\ \text{(subject to)} \\ \mathbf{w}_1^T \mathbf{w}_1 = 1 \end{aligned}$$

Varyans ifadesine dönersek:

$$\sigma^2 = \mathbf{w}_1^{*T} \mathbf{S} \mathbf{w}_1^* = \mathbf{w}_1^{*T} \alpha \mathbf{w}_1^* = \alpha \underbrace{\mathbf{w}_1^{*T} \mathbf{w}_1^*}_{=1} = \alpha,$$

varyansı maksimize etmek istediğimiz için **en büyük özdeğere karşılık gelen özvektörü seçeriz.**

Bu nedenle, **birinci temel bileşen** veri kovaryans matrisinin en büyük özdeğerine ($\lambda_1 = \alpha$) karşılık gelen özvektörüdür.

İkinci temel bileşen $\mathbf{w}_2$ de (i) varyansı maksimize etmeli, (ii) birim uzunlukta olmalı ve (iii) $\mathbf{w}_1'$ e dik olmalıdır. Son koşul izdüşümden sonra elde ettiğimiz $z_2 = \mathbf{w}_2^T \mathbf{x}$ ile z_1' in korelasyonsuz olması anlamına gelir.

İkinci temel bileşen için ilgili Lagrange optimizasyon problemi şöyledir:

$$\mathbf{w}_2^* = \underset{\mathbf{w}_2}{\operatorname{argmax}} \left(\mathbf{w}_2^T \mathbf{S} \mathbf{w}_2 - \alpha (\mathbf{w}_2^T \mathbf{w}_2 - 1) - \beta (\mathbf{w}_2^T \mathbf{w}_1 - 0) \right)$$

$\mathbf{w}_2$ 'ye göre türev alıp sonucu 0'a eşitlediğimizde, şunu elde ederiz:

$$2\mathbf{S}\mathbf{w}_2 - 2\alpha\mathbf{w}_2 - \beta\mathbf{w}_1 = 0 \quad (*)$$

(*) denkleminde her iki tarafı soldan $\mathbf{w}_1^T$ ile çarparsak şunu elde ederiz:

$$2\mathbf{w}_1^T \mathbf{S} \mathbf{w}_2 - 2\alpha \mathbf{w}_1^T \mathbf{w}_2 - \beta \mathbf{w}_1^T \mathbf{w}_1 = 0 \quad (**)$$

$$\underbrace{2\mathbf{w}_1^T \mathbf{S} \mathbf{w}_2}_{2\mathbf{w}_2^T \mathbf{S} \mathbf{w}_1 = 2\mathbf{w}_2^T \alpha \mathbf{w}_1 = 0} - \underbrace{2\alpha \mathbf{w}_1^T \mathbf{w}_2}_0 - \underbrace{\beta \mathbf{w}_1^T \mathbf{w}_1}_{\beta} = 0 \quad (**)$$

$$\Rightarrow \beta = 0$$

Buna göre, (*) ifadesinden şunu elde ederiz:

$$2\mathbf{S}\mathbf{w}_2 - 2\alpha\mathbf{w}_2 - \beta\mathbf{w}_1 = 0 \Rightarrow \mathbf{S}\mathbf{w}_2 = \alpha\mathbf{w}_2$$

Bu nedenle, **ikinci temel bileşen** veri kovaryans matrisi $\mathbf{S}$ 'in en büyük ikinci özdeğerine ($\lambda_2 = \alpha$) karşılık gelen özvektörüdür.

Benzer şekilde, **diğer temel bileşenlerin** de $\mathbf{S}$ matrisinin azalan özdeğerlere karşılık gelen özvektörleri olduğu gösterilebilir.

$$\mathbf{S} = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}^i - \bar{\mathbf{x}})(\mathbf{x}^i - \bar{\mathbf{x}})^T$$

Gözlemler:

- $\mathbf{S}$ simetrik bir matristir.
- $\mathbf{S}$ her zaman pozitif yarı tanımlıdır (positive semi-definite): $\mathbf{a}^T \mathbf{S} \mathbf{a} \geq 0$, tüm $\mathbf{a}$ 'lar için.
- Yeterli sayıda eğitim örneğimiz olduğunda (kaç tane?), $\mathbf{S}$ tam rütbeli (full-rank) olur.
 - Bu durumda $\mathbf{S}$ pozitif tanımlıdır ($\mathbf{a}^T \mathbf{S} \mathbf{a} > 0$, sıfırdan farklı tüm $\mathbf{a}$ 'lar için) ve dolayısıyla tüm özdeğerleri pozitiftir.
 - Böylece, lineer cebirden biliyoruz ki $\mathbf{S}$ matrisi için d tane sıfırdan farklı özdeğere karşılık gelen ve birbirine dik olan d farklı özvektör hesaplanabilir.
- Eğer $\mathbf{S}$ tekil (singular) ise, rütbesi (rank'i) ve etkin boyutu k 'dır ve $k < d$ olur. Bu durumda, $i = k + 1, \dots, d$ için $\lambda_i = 0$ 'dır (λ_i 'lerin büyükten küçüğe sıralandığını varsayıyoruz). Sıfırdan farklı özdeğerlere sahip k özvektör, indirgenmiş uzayın boyutlarını oluşturur.

Adım 1: eğitim verilerinden veri kovaryans matrisi S 'yi hesapla.

Adım 2: S matrisinin en büyük k özdeğerine karşılık gelen k tane özvektörü hesapla.

Adım 3: izdüşüm matrisini oluştur:

$$\mathbf{W} = \begin{bmatrix} \mathbf{w}_1 & \mathbf{w}_2 & \cdots & \mathbf{w}_k \end{bmatrix}_{d \times k}$$

Adım 4: herhangi bir $\mathbf{x} \in \mathbb{R}^d$ için, onu $\mathbf{z} \in \mathbb{R}^k$ 'ye şu şekilde eşle:

$$\mathbf{z} = \mathbf{W}^T \mathbf{x}$$

veya

$$\mathbf{z} = \mathbf{W}^T (\mathbf{x} - \bar{\mathbf{x}}) \quad (\text{veri izdüşümden önce merkezileştirilir.})$$

Not: İzdüşürülen noktaların yeni boyutlar üzerindeki varyansları S matrisinin özdeğerlerine eşittir.




Fig: PCA'de tüm özdeğerlerin dağılımı için örnek.


- ❑ k temel bileşen tarafından açıklanan varyans oranı (**Proportion of Variance (PoV)**):

$$\text{PoV} = \frac{\lambda_1 + \lambda_2 + \cdots + \lambda_k}{\lambda_1 + \lambda_2 + \cdots + \lambda_k + \cdots + \lambda_d}$$

Burada λ_i 'ler **büyükten küçüğe doğru sıralanmıştır**.

- ❑ Genellikle, $\text{PoV} > 0.9$ olduğunda durulur.
- ❑ **Scree grafiği (Scree graph)**, k 'ye karşı özdeğerlerin (veya PoV'nin) çizimidir; varsa “**dirsek**” noktasında durulması önerilir.

$$\mathbf{z} = \mathbf{W}^T(\mathbf{x} - \bar{\mathbf{x}}) \quad (\text{Veri izdüşümünden önce merkezileştirilir.})$$



PCA veriyi orijinde merkezler ve eksenleri döndürür.

- ❑ Orijinal öznitelik x_i 'lerin varyansları birbirinden oldukça farklıysa, bu durum temel bileşenlerin yönünü korelasyonlardan daha fazla etkiler.
 - Eğer bir özneliğin varyansı diğerlerine göre belirgin biçimde daha büyükse, bu öznitelik birinci temel bileşene baskın şekilde yön verir.
 - Yaygın bir uygulama, PCA uygulanmadan önce veriyi ön işleyerek (preprocessing) her boyutun ortalamasını 0 ve varyansını 1 yapmaktır.
 - Alternatif olarak, tek tek varyansların değil korelasyonların etkili olması için, kovaryans matrisi $\mathbf{S}$ yerine korelasyon matrisi $\mathbf{R}$ 'nin özvektörleri kullanılabilir.

$$R_{ij} = \frac{S_{ij}}{\sigma_i \sigma_j} = \frac{S_{ij}}{\sqrt{S_{ii}} \sqrt{S_{jj}}}$$

- ❑ PCA varyansı açıklar ve aykırı değerlere (outliers'a) duyarlıdır: merkezden uzak birkaç nokta, varyanslar ve dolayısıyla özvektörler üzerinde büyük etkiye sahip olabilir.
- ❑ Eğer ilk iki veya üç temel bileşen varyansın büyük bir yüzdesini açıklıyorsa, **görsel analiz** yapılabilir.

Örnek: Beş derse ait notları verilen bir öğrenci grubu olduğunu ve bu öğrencileri sıralamak istediğimizi varsayalım.

- Bu problem, veri noktaları arasındaki farkın en belirgin hâle gelmesini sağlayacak şekilde veriyi **tek bir boyuta yansıtma** problemine eşdeğerdir.
- PCA kullanabiliriz. En büyük özdeğere karşılık gelen özvektör, en yüksek varyansa sahip yönü, yani öğrencilerin en fazla yayıldığı yönü verir.

Not: PCA tabanlı bu çözüm, ortalama almaya göre daha iyi çalışır; çünkü korelasyonları ve varyanslardaki farklılıkları da dikkate alır.

❑ **Kırpma olmadan** tam ters PCA dönüşümü ($\mathbf{A}$ 'nın terslenebilir ve $k = d$ olduğu varsayımıyla):

$$\hat{\mathbf{x}} = \mathbf{A}^{-1} \mathbf{z} = \mathbf{A}^T \mathbf{z} = \underbrace{\mathbf{A}^T \mathbf{A}}_{\mathbf{I}} \mathbf{x} = \mathbf{x}$$

❑ **Kırpılmış** ters PCA dönüşümü ($k < d$):

Yöntem 1: $\hat{\mathbf{x}} = \mathbf{A}^T \mathbf{z} \neq \mathbf{x}$

Yöntem 2: $\hat{\mathbf{x}} = \mathbf{A}^T \mathbf{z} + (\mathbf{I} - \mathbf{A}^T \mathbf{A}) \bar{\mathbf{x}} \neq \mathbf{x}$

PCA / Ters PCA'nın görüntü sıkıştırma uygulaması (1)

orijinal



İlk 50 PCA bileşeni kullanılarak
görüntü sıkıştırma.



sıkıştırılmış



Kırpılmış PCA ($k < d$):

Yöntem 1: $\hat{x} = \mathbf{A}^T \mathbf{z} \neq \mathbf{x}$

Yöntem 2: $\hat{x} = \mathbf{A}^T \mathbf{z} + (\mathbf{I} - \mathbf{A}^T \mathbf{A}) \bar{x} \neq \mathbf{x}$

Fig: A 512 x 512 boyutunda gri bir görüntü ve bu görüntünün ilk 50 PCA bileşeni kullanılarak yeniden elde edilmiş hâli.


original

$k = 2$

$k = 50$

$k = 100$

$k = 300$



Görsel tanıma uygulamalarında —örneğin yüz tanıma— $\hat{x}$ 'in gösterilmesi, PCA sırasında bilgi kaybının görsel olarak kontrol edilmesine olanak sağlar.

Fig: 28x28 boyutlu görüntünün ($d = 784$), daha düşük boyutlu PCA izdüşümlerinden ($k = 2, 50, 100, 300$) yeniden oluşturulmuş örnekleri.

orijinal



Image compression using
the first 50 PCAs.

sıkıştırılmış



Fig: A 512 x 512 boyutunda gri bir görüntü ve bu görüntünün ilk 50 PCA bileşeni kullanılarak yeniden elde edilmiş hâli.

Q: Bu PCA tabanlı görüntü sıkıştırma örneklerinde S (veri kovaryans matrisi) nedir?

original

$k = 2$

$k = 50$

$k = 100$

$k = 300$



Fig: 28×28 boyutlu görüntülerin ($d = 784$), daha düşük boyutlu PCA izdüşümlerinden ($k = 2, 50, 100, 300$) yeniden oluşturulmuş örnekleri.

Doğrusal Ayırt Edici Analiz (Linear Discriminant Analysis (LDA))

Doğrusal ayırt edici analiz (LDA), **sınıflandırma** problemlerinde boyut indirgeme için kullanılan **denetimli** bir yöntemdir.

LDA'nın amacı: veriyi, sınıflar arasındaki ayrımı maksimize edecek şekilde yansıtmak için doğrusal bir eşleme (mapping) belirlemektir.

LDA'da **sınıf etiketleri bilinir** ve izdüşüm (mapping) için bu bilgi kullanılır.

Bu derste iki sınıfın olduğu durumu ($K = 2$) ele alacağız sadece. $K > 2$ için paylaşılan makine öğrenmesi ders notlarına bakınız lütfen.

İzdüşümün amacı izdüşüm sonrasında sınıflar arasındaki ayırımı maximize etmek olduğunda, PCA bazı durumlarda başarısız olabilir:




Fig. Tek boyutlu izdüşüm için LDA ve PCA karşılaştırması.

$z = \mathbf{w}^T \mathbf{x} \longrightarrow \mathbf{x}$ 'in $\mathbf{w}$ üzerine izdüşümüdür ve dolayısıyla d boyutundan 1 boyuta bir boyut indirgemedir.

$\mathcal{X} = \{\mathbf{x}^t, r^t\}_{t=1, \dots, N}$ örneklerinin verildiğini varsayalım. Burada, eğer $\mathbf{x}^t \in \mathcal{C}_1$ ise $r^t = 1$ ve eğer $\mathbf{x}^t \in \mathcal{C}_2$ ise $r^t = 0$ 'dır.

$\mathbf{m}_i$ ve m_i , $i = 1, 2$ için, sırasıyla $\mathcal{C}_i$ sınıfına ait örneklerin izdüşüm öncesi ve izdüşüm sonrası ortalamalarını gösterebilir:

$$m_i = \mathbf{w}^T \mathbf{m}_i$$

$\mathcal{C}_1$ ve $\mathcal{C}_2$ sınıflarına ait örneklerin izdüşüm sonrası **saçılımı (scatter'i)** şöyledir:

$$s_1^2 = \sum_t (\mathbf{w}^T \mathbf{x}^t - m_1)^2 r^t$$


$$s_2^2 = \sum_t (\mathbf{w}^T \mathbf{x}^t - m_2)^2 (1 - r^t)$$

İzdüşümden sonra, iki sınıfın iyi ayrılabilmesi için **ortalamaların birbirinden mümkün olduğunca uzak olmasını** ve sınıflara ait örneklerin mümkün olduğunca dar bir bölgede toplanmasını isteriz.

$$J(\mathbf{w}) = \frac{(m_1 - m_2)^2}{s_1^2 + s_2^2} \quad \rightarrow \quad \text{maximize edilecek}$$



Fisher'in doğrusal ayırt edicisi, $J(\mathbf{w})$ 'yi maksimize eden $\mathbf{w}^*$ 'dir.



$$J(\mathbf{w}) = \frac{(m_1 - m_2)^2}{s_1^2 + s_2^2}$$

Payı yeniden yazarsak, şunu elde ederiz:

$$\begin{aligned}(m_1 - m_2)^2 &= (\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2)^2 \\ &= \mathbf{w}^T \underbrace{(\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T}_{\mathbf{S}_B} \mathbf{w} \\ &= \mathbf{w}^T \mathbf{S}_B \mathbf{w}\end{aligned}$$

($\mathbf{S}_B$: the **between-class** scatter matrix)

Payda, izdüşümden sonra sınıflara ait örneklerin kendi ortalamaları etrafındaki saçılımlarının toplamıdır ve şu şekilde yeniden yazılabilir:

$$\begin{aligned}s_1^2 &= \sum_t (\mathbf{w}^T \mathbf{x}^t - m_1)^2 r^t \\ &= \sum_t \mathbf{w}^T (\mathbf{x}^t - \mathbf{m}_1)(\mathbf{x}^t - \mathbf{m}_1)^T \mathbf{w} r^t \\ &= \mathbf{w}^T \underbrace{\sum_t r^t (\mathbf{x}^t - \mathbf{m}_1)(\mathbf{x}^t - \mathbf{m}_1)^T}_{\mathbf{S}_1} \mathbf{w}\end{aligned}$$

Benzer bir şekilde,

$$s_2^2 = \mathbf{w}^T \underbrace{\sum_t (1 - r^t) (\mathbf{x}^t - \mathbf{m}_2)(\mathbf{x}^t - \mathbf{m}_2)^T}_{\mathbf{S}_2} \mathbf{w}$$

$$J(\mathbf{w}) = \frac{(m_1 - m_2)^2}{s_1^2 + s_2^2}$$

Şunları biliyoruz:

$$(m_1 - m_2)^2 = \mathbf{w}^T \mathbf{S}_B \mathbf{w}$$

$$s_1^2 + s_2^2 = \mathbf{w}^T \underbrace{(\mathbf{S}_1 + \mathbf{S}_2)}_{\mathbf{S}_W} \mathbf{w} \quad (\mathbf{S}_W: \text{the within-class scatter matrix})$$

$$\Rightarrow J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$$

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$$

J 'nin $\mathbf{w}$ 'ye göre türevini alıp bunu 0'a eşitlediğimizde, şunu elde ederiz:

$$\mathbf{w}^T \frac{(\mathbf{m}_1 - \mathbf{m}_2)}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} 2 \left((\mathbf{m}_1 - \mathbf{m}_2) - \frac{\mathbf{w}^T (\mathbf{m}_1 - \mathbf{m}_2)}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} \mathbf{S}_W \mathbf{w} \right) = 0$$

$$\Rightarrow \mathbf{w} = \mathbf{S}_W^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \quad (d \text{ boyuttan } 1 \text{ boyuta izdüşüm yapmak için})$$

Örnek ($K = 2$, iki sınıf için): PCA ve LDA








Fig: İki boyutlu sentetik veri üzerinde, PCA ve LDA tarafından bulunan yönler ile bu yönler boyunca elde edilen izdüşümler gösterilmektedir. LDA, sınıf bilgisini kullandığı için, beklendiği üzere sınıfların ayrılması açısından çok daha başarılı sonuç verir.

Destek Vektör Makineleri (Support Vector Machines (SVMs))

Bu sınıflandırma örneği için hangi ayırıcıyı seçersiniz?




Gürültülü veriye karşı dayanıklılık (Robustness to noisy data)



Gürültüye karşı dayanıklı olmak (örneğin ölçüm hatalarına karşı) istenen bir özelliktir.

Daha kalın bir “**tampon bölge**”, daha yüksek dayanıklılık anlamına gelir



Bu tür hiper düzlemlere “**kalın**” hiper düzlemler denir.

1. En kalın ayırıcı hiper düzlemi etkin bir şekilde bulabilir miyiz?
2. Daha kalın bir hiper düzlem, daha ince bir hiper düzlemden daha mı iyidir? Eğer öyleyse, neden?
3. Veriler doğrusal olarak ayrılabilir değilse ne yapmalıyız?

Önceden

$$\mathbf{x} \in \{1\} \times \mathbb{R}^d; \quad \mathbf{w} \in \{1\} \times \mathbb{R}^d$$

$$\mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_d \end{bmatrix}; \quad \mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_d \end{bmatrix}$$

$$\text{sinyal} = \mathbf{w}^T \mathbf{x}$$

Şimdi

$$\mathbf{x} \in \mathbb{R}^d; \quad b \in \mathbb{R}, \mathbf{w} \in \mathbb{R}^d$$

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix}; \quad \mathbf{w} = \begin{bmatrix} w_1 \\ \vdots \\ w_d \end{bmatrix}$$

bias b


$$\text{sinyal} = \mathbf{w}^T \mathbf{x} + b$$


Bunun nedeni, daha sonra geliştirilecek matematiksel ifadelerin bu iki ağırlık türünü farklı biçimde ele alacak olmasıdır.

Maksimum marjlı ayırıcı hiper düzlem (Maximum-margin separating hyperplane)

Maksimum marjlı ayırıcı hiper düzlemin iki ayırt edici özelliği vardır.

1. Veriyi ayırır.
2. Veriyi ayıran hiper düzlemler arasında en kalın tampon bölgeye sahiptir.





$\mathbf{x}^n$: n . veri noktasının öznitelik vektörü

Tanım: ayırıcı hiper düzlem

h hiper düzlemi, ancak ve ancak kendisini temsil eden $(b, \mathbf{w})$ parametreleri aşağıdaki koşulu sağlıyorsa veriyi ayırır:

$$\min_{n=1, \dots, N} y^n (\mathbf{w}^T \mathbf{x}^n + b) = 1$$


Aşağıdaki iki koşulun eşdeğer olduğuna dikkat ediniz:

$$y^n (\mathbf{w}^T \mathbf{x}^n + b) > 0, \quad n = 1, \dots, N \quad (*)$$

$$\min_{n=1, \dots, N} y^n (\mathbf{w}^T \mathbf{x}^n + b) = 1 \quad (**)$$

Ayırıcı bir hiper düzlemin kalınlığı (Fatness of a separating hyperplane)

Kalınlık = ayırıcının en yakın noktaya olan uzaklığı.



hiper düzlem h : $\mathbf{w}^T \mathbf{x} + b = 0$

$$\text{Kalınlık}(\text{margin } \gamma(h)) = \frac{1}{\|\mathbf{w}\|}$$

Marjı maksimize etme (Maximizing the margin) (1)

$$\text{margin } \gamma(h) = \frac{1}{\|\mathbf{w}\|}$$

← Sabit terim (bias term) b ifadede yer almıyor.

Dikkat ediniz ki, b terimi optimize edilen nicelikte yer almıyor; ancak kısıt içinde bulunuyor.

$$\max_{b, \mathbf{w}} \frac{1}{\|\mathbf{w}\|} \quad \text{kısıtı altında}$$

kısıtı altında
(subject to)

$$\min_{n=1, \dots, N} y^n (\mathbf{w}^T \mathbf{x}^n + b) = 1 \quad \leftarrow \text{veriyi ayırma koşulu}$$

III

$$\min_{b, \mathbf{w}} \{\|\mathbf{w}\| = \sqrt{\mathbf{w}^T \mathbf{w}}\}$$

kısıtı altında
(subject to)

$$\min_{n=1, \dots, N} y^n (\mathbf{w}^T \mathbf{x}^n + b) = 1$$

(neden?)

≡

$$\min_{b, \mathbf{w}} \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

kısıtı altında
(subject to)

$$\min_{n=1, \dots, N} y^n (\mathbf{w}^T \mathbf{x}^n + b) = 1$$

Marjı maksimize etme (Maximizing the margin) (2)

$$\min_{b, \mathbf{w}} \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

kısıtı altında
(subject to) (*)

$$\min_{n=1, \dots, N} y^n (\mathbf{w}^T \mathbf{x}^n + b) = 1$$



(ispat için paylaşılan ML notlarına bakınız lütfen)

$$\min_{b, \mathbf{w}} \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

kısıtı altında
(subject to) (**)

$$y^n (\mathbf{w}^T \mathbf{x}^n + b) \geq 1, \quad n = 1, \dots, N.$$

$$\min_{\mathbf{u} \in \mathbb{R}^q} \frac{1}{2} \mathbf{u}^T Q \mathbf{u} + \mathbf{p}^T \mathbf{u}$$

kısıtı altında (subject to): $A \mathbf{u} \geq \mathbf{c}$

Tanım (Hard-margin SVM)

Sert-marjlı (hard-margin) SVM, verilerin doğrusal olarak tamamen ayrılabilir olduğunu varsayan ve hiçbir sınıflandırma hatasına izin vermeden maksimum marjlı ayırıcı hiper düzlemi bulan SVM yaklaşımıdır.

“Hard-margin” SVM için primal ve dual optimization problemleri

Primal

$$\min_{b, \mathbf{w}} \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

kısıtı altında
(subject to)

$$y^n(\mathbf{w}^T \mathbf{x}^n + b) \geq 1, \quad n = 1, \dots, N.$$

$d + 1$ karar değişkeni $\mathbf{w}, b$

$$g(\mathbf{x}) = \text{sign}(\mathbf{w}^{*T} \mathbf{x} + b^*)$$

Dual

$$\min_{\alpha \in \mathbb{R}^N} \left\{ \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N y_n y_m \alpha_n \alpha_m \mathbf{x}^n{}^T \mathbf{x}^m - \sum_{n=1}^N \alpha_n \right\}$$

kısıtı altında
(subject to)

$$\sum_{n=1}^N \alpha_n y^n = 0$$


$$\alpha_n \geq 0 \quad (n = 1, \dots, N)$$

N karar değişkeni α

$$\mathbf{w}^* = \sum_{\alpha_n^* > 0} y^n \alpha_n^* \mathbf{x}^n \quad b^* = y^s - \mathbf{w}^{*T} \mathbf{x}^s \longrightarrow \text{destek vektörü öyle ki } \alpha_s^* > 0$$


$$g(\mathbf{x}) = \text{sign} \left(\sum_{\alpha_n^* > 0} y^n \alpha_n^* \mathbf{x}^n{}^T (\mathbf{x} - \mathbf{x}^s) + y^s \right)$$

“Destek vektörleri” adlandırmasına ilişkin bazı açıklamalar



Bunlara “**destek vektörleri**” denir; çünkü bir anlamda tampon bölgeyi “**desteklerler**” ve onun daha fazla genişlemesini engellerler.


Örnekten bazı gözlemler




- ❑ Yukarıdaki örnekten daha sonra işimize yarayacak bazı önemli gözlemler yapalım.
- ❑ Bu örnekte, destek vektörü olmayan 4. veri noktasını kaldırırsak optimal hiper düzleme ne olur?

Hiçbir şey!

- ❑ Hiper düzlem, **aynı marj** ile ayırıcı olmaya devam eder. Bir veri noktasını kaldırmış olsak da, daha büyük bir marj elde edilmedi bu örnekte; çünkü daha önce marjın genişlemesini engelleyen tüm destek vektörleri hâlâ veri kümesinde bulunmaktadır. Dolayısıyla hiper düzlem optimal kaldı.
- ❑ Gerçekten de, optimal hiper düzlemi hesaplamak için **yalnızca destek vektörlerine ihtiyaç vardır**; diğer veriler göz ardı edilebilir.




→ hataya tolerans göster



→ doğrusal olmayan dönüşüm uygula

İkinci şekildekine benzer durumlarda veriyi ayrılabilir hâle getirmek için, veriyi genellikle daha yüksek boyutlu bir uzaya transform ederiz: $\Phi : \mathbb{R}^d \rightarrow \mathbb{R}^{\tilde{d}}$. Transform edilmiş veriler:

$$\mathbf{z}^n = \Phi(\mathbf{x}^n), \quad \mathbf{x}^n : n.\text{verinin öznitelik vektörü}$$



Doğrusal olarak ayrılabilir
olmayan veri

$$\mathbf{z}^n = \Phi(\mathbf{x}^n),$$

$\mathbf{x}^n$: n .verinin öznitelik vektörü


$$\min_{\tilde{b}, \tilde{\mathbf{w}}} \frac{1}{2} \tilde{\mathbf{w}}^T \tilde{\mathbf{w}}$$

kısıtı altında
(subject to)


$$y^n(\tilde{\mathbf{w}}^T \mathbf{z}^n + \tilde{b}) \geq 1, \quad n = 1, \dots, N.$$

Algoritma, optimal çözüm olarak $\tilde{b}^*, \tilde{\mathbf{w}}^*$ değerlerini döndürür ve nihai hipotez şu şekildedir:

$$g(\mathbf{x}) = \text{sign}(\tilde{\mathbf{w}}^{*T} \Phi(\mathbf{x}) + \tilde{b}^*)$$



$\Phi_2 + \text{SVM}$



$\Phi_3 + \text{SVM}$

Fig: SVM ile 2. ve 3. dereceden polinom transformasyonları kullanılarak doğrusal olmayan ayırma

Gözlemler:


- $\Phi_3(\tilde{d}_3 = 9)$ 'ün parametre sayısı nerdeyse $\Phi_2(\tilde{d}_2 = 5)$ 'in parametre sayısının iki katı.
- " $\Phi_3 + \text{SVM}$ " 'in destek vektör sayısı " $\Phi_2 + \text{SVM}$ " 'e göre iki katına çıkmadı, sadece 5'den 6'ya yükseldi.
- Destek vektör sayısı küçük kaldığı veya marj büyük kaldığı sürece daha yüksek boyutlara çıkabiliriz.

Daha yüksek boyutlarda aşırı uyumu (overfitting) $\#$ destek vektörleri veya marj ρ ile kontrol edebiliriz.

Bu durumda, peki:

- Verimlilik ne olacak?
- Sonsuz sayıda boyut da düşünebilir miyiz?

Yumuşak marj (Soft margin) SVM



Hataya tolerans göster

$$\min_{b, \mathbf{w}, \xi} \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{n=1}^N \xi_n$$

kısıtlı altında
(subject to)

$$y^n(\mathbf{w}^T \mathbf{x}^n + b) \geq 1 - \xi_n, \quad n = 1, \dots, N.$$
$$\xi_n \geq 0, \quad n = 1, \dots, N.$$

“yumuşak örnek-içi hata”
 (“soft in-sample error”)

$(\mathbf{x}^n, y^n)$ için “yumuşak” hata
 (“soft” error on $(\mathbf{x}^n, y^n)$)

Sert marjlı SVM’de eğer $y^n(\mathbf{w}^T \mathbf{x}^n + b) = 1$ ise, ilgili veri noktasının marjın sınırı üzerinde olduğunu hatırlayınız. Dolayısıyla, yumuşak marjda ξ_n veri noktasının marjın içine ne kadar girdiğini ifade eder.

- ❑ “Çekirdek fonksiyonu” + “çekirdek numarası” (“kernel function”+kernel trick), doğrusal olmayan transformasyonların yüksek boyutlu uzaylarda verimli bir şekilde kullanılmasını sağlayan bir mekanizmadır.
- ❑ Bu mekanizmayı **keşfetmek** için SVM'lere “**dual optimizasyon formülasyonu**” açısından bakmamız gerekir.

Dual SVMs vasıtasıyla çekirdek fonksiyonu ve çekirdek numarası (1)

Dual SVM problemine transformasyon uzayında, $\mathcal{Z}$ uzayında bakacağız. $\mathcal{Z}$ uzayındaki dual problemi, $\mathcal{X}$ -uzayındaki dual SVM probleminde yer alan her $\mathbf{x}^n$ 'in $\mathbf{z}^n = \Phi(\mathbf{x}^n)$ ile değiştirilmesinden elde edilir.

Orjinal uzay $\mathcal{X}$ 'de hard-margin dual SVM problemi

$$\min_{\alpha \in \mathbb{R}^N} \left\{ \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N y^n y^m \alpha_n \alpha_m \mathbf{x}^{nT} \mathbf{x}^m - \sum_{n=1}^N \alpha_n \right\}$$

kısıtı altında
(subject to)

$$\sum_{n=1}^N \alpha_n y^n = 0$$

$$\alpha_n \geq 0 \quad (n = 1, \dots, N)$$

$$g(\mathbf{x}) = \text{sign} \left(\sum_{\alpha_n^* > 0} y_n \alpha_n^* \mathbf{x}^{nT} (\mathbf{x} - \mathbf{x}^s) + y^s \right)$$

Transform uzayı $\mathcal{Z}$ 'de hard-margin dual SVM problemi

$$\min_{\alpha \in \mathbb{R}^N} \left\{ \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N y^n y^m \alpha_n \alpha_m \mathbf{z}^{nT} \mathbf{z}^m - \sum_{n=1}^N \alpha_n \right\}$$

kısıtı altında
(subject to)

$$\sum_{n=1}^N \alpha_n y^n = 0$$

$$\alpha_n \geq 0 \quad (n = 1, \dots, N)$$

$$\tilde{g}(\mathbf{z}) = \text{sign} \left(\sum_{\alpha_n^* > 0} y^n \alpha_n^* \mathbf{z}^{nT} (\mathbf{z} - \mathbf{z}^s) + y^s \right)$$

Dual SVMs vasıtasıyla çekirdek fonksiyonu ve çekirdek numarası (2)

Şimdi, $\mathcal{Z}$ -uzayındaki dual SVM çözümüne dayanarak doğrusal olmayan SVM problemini çözmek için bir prosedür verebiliriz. Bu prosedür, $\mathcal{X}$ -uzayı için olan dual algoritmada $\mathbf{x}$ yerine $\mathbf{z} = \Phi(\mathbf{x})$ yazılarak doğrudan elde edilebilir:

1. Input: $\{\mathbf{x}^n\}, \{y^n\}$.
2. $\mathbf{p} = -\mathbf{1}_N$ N-boyutlu birler vektörü ve $\mathbf{c} = \mathbf{0}_{N+2}$ N+2-boyutlu sıfırlar vektörü olsun. Q_D ve A_D matrislerini aşağıdaki gibi oluşturalım:

$$\underbrace{Z_s = \begin{bmatrix} - & - & y^1 \Phi(\mathbf{x}^1)^T & - & - \\ & & \vdots & & \\ - & - & y^N \Phi(\mathbf{x}^N)^T & - & - \end{bmatrix}}_{\text{işaretli veri matrisi}}, Q_D = Z_s Z_s^T = \begin{bmatrix} y^1 y^1 \Phi(\mathbf{x}^1)^T \Phi(\mathbf{x}^1) & \cdots & y^1 y^N \Phi(\mathbf{x}^1)^T \Phi(\mathbf{x}^N) \\ y^2 y^1 \Phi(\mathbf{x}^2)^T \Phi(\mathbf{x}^1) & \cdots & y^2 y^N \Phi(\mathbf{x}^2)^T \Phi(\mathbf{x}^N) \\ \vdots & \vdots & \vdots \\ y^N y^1 \Phi(\mathbf{x}^N)^T \Phi(\mathbf{x}^1) & \cdots & y^N y^N \Phi(\mathbf{x}^N)^T \Phi(\mathbf{x}^N) \end{bmatrix}, A_D = \begin{bmatrix} \mathbf{y}^T \\ -\mathbf{y}^T \\ I_{N \times N} \end{bmatrix}$$

3. $\boldsymbol{\alpha}^* \leftarrow \text{QP}(Q_D, \mathbf{p}, A_D, \mathbf{c})$

4. Döndür

$$\mathbf{w}^* = \sum_{\alpha_n^* > 0} y^n \alpha_n^* \mathbf{z}^n = \sum_{\alpha_n^* > 0} y^n \alpha_n^* \Phi(\mathbf{x}^n)$$

$$b^* = y^s - \mathbf{w}^{*T} \mathbf{z}^s = y^s - \mathbf{w}^{*T} \Phi(\mathbf{x}^s) = y^s - \sum_{\alpha_n^* > 0} y^n \alpha_n^* \Phi(\mathbf{x}^n)^T \Phi(\mathbf{x}^s) \quad (\alpha_s^* > 0)$$

5. Elde edilen model: $g(\mathbf{x}) = \tilde{g}(\mathbf{z}) = \text{sign}(\mathbf{w}^{*T} \mathbf{z} + b^*) = \text{sign}(\mathbf{w}^{*T} \Phi(\mathbf{x}) + b^*)$

- Prosedür boyunca, $\Phi(\mathbf{x})$ 'in boyutu olan $\tilde{d}$ 'ye bağlı olabilecek tek adım $\mathcal{Z}$ -uzayındaki iç çarpımın (inner product'ın) hesaplanmasıdır:

$$\Phi(\mathbf{x})^T \Phi(\mathbf{x}')$$

- Bu iç çarpım, Q_D 'nin oluşturulmasında ve $g(\mathbf{x})$ ifadesinde gereklidir.
- “Kernel trick (çekirdek numarası)” şu fikre dayanır:
 - transformasyonu **ve** iç çarpımı **birlikte** hesaplama,
 - Hesaplamayı $\mathcal{X}$ uzayında yapma (dolayısıyla $\mathcal{Z}$ -uzayına geçmeye gerek yoktur).
- Dolayısıyla, kernel trick sayesinde dönüşüm ve iç çarpım, $\tilde{d}$ 'den bağımsız olarak verimli bir şekilde hesaplanabilir.
- Şimdi, hem dönüşümü hem de iç çarpımı birleştiren ve “çekirdek fonksiyonu (kernel function)” olarak adlandırılan bir fonksiyon tanımlayalım:

$$\mathcal{K}_{\Phi}(\mathbf{x}, \mathbf{x}') := \Phi(\mathbf{x})^T \Phi(\mathbf{x}')$$

- Örnek olarak iki nonlinear Φ transformasyona karşılık gelen K_{Φ} fonksiyonlarını görelim.

Derecesi Q olan polinom çekirdeği:

$$\mathcal{K}(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^Q$$

burada $\gamma > 0$, $\zeta > 0$ ve $Q \in \mathbb{N}$ 'dir.

$Q = 2$ 'a karşılık gelen transformasyon:

$$\Phi_2(\mathbf{x}) = (\zeta \cdot 1, \sqrt{2\gamma\zeta} \cdot x_1, \sqrt{2\gamma\zeta} \cdot x_2, \dots, \sqrt{2\gamma\zeta} \cdot x_d, \gamma \cdot x_1x_1, \gamma \cdot x_1x_2, \dots, \gamma \cdot x_dx_d)$$

Bir diğer popüler çekirdek “Gaussian-RBF çekirdeği (Gaussian-RBF Kernel)” olarak adlandırılır ve şu forma sahiptir:

$$\mathcal{K}(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2) \quad (\gamma > 0)$$

Skaler duruma karşılık gelen transformasyon:

$$\Phi(x) = \exp(-x^2) \left(1, \sqrt{\frac{2^1}{1!}}x, \sqrt{\frac{2^2}{2!}}x^2, \sqrt{\frac{2^3}{3!}}x^3, \dots \right)$$

Soft-margin SVM de bir çekirdek ile birlikte kullanılabilir. O hâlde, özet olarak SVM şunları yapabilir:

1. geniş marjlı bir hiper düzlem elde edebilir ve bunu yaparken etkin model karmaşıklığını (complexity'i) kontrol edebilir.

2. bir çekirdek kullandığında, “**kernel trick**” sayesinde yüksek boyutlu veya sonsuz boyutlu transformasyonlarla başa çıkabilir.

3. son hipotez (model) $g(\mathbf{x})$ 'i yalnızca birkaç destek vektörü, bunlara karşılık gelen Lagrange çarpanları ve çekirdek kullanarak ifade edebilir.

4. **aykırı değerlere duyarlılık kontrol edilebilir ve C parametresi uygun şekilde seçilerek çözüm düzenlenebilir.**

□ C düzenleme parametresi ve çekirdek uygun şekilde seçildiğinde, soft-margin SVM'in yukarıdaki yararlı özelliklerle birlikte çoğu zaman düşük bir E_{out} (test hatası) sağladığı gözlemlenir.

□ Bu özellikler soft-margin SVM'i en yararlı sınıflandırma modellerinden biri hâline getirir ve veriden öğrenmede onu çoğu zaman **ilk tercih** yapar.

□ SVM uygun bir çekirdek ile kullanıldığında gelişmiş doğrusal olmayan transformasyon yeteneğine sahip ve dayanıklı (robust) bir doğrusal modeldir.